



競賽經驗談:從國內

競賽到 Kaggle 實戰

Yung-Chuan Lee 2017.03



我的養成

104 上半年度產投課程 - Big Data 資料 分析概論班 2015-08-30(日) 至 2015-09-13(日)

行雲流水軟體 AppCloudom Softs Spark/Scala大數據分析技術與應用 2015年12月21日





- **=2015/06** 決定投入大數據領域
- ■2015/09 參加胡老師「104上半年度產投課程 Big Data 資料分析概論班」

■2015/12 參加胡老師「Spark/Scala大數據分析技術與應

用」

-2016/03 開始在Kaggle修練經驗值

Santander Customer Sati... 2,790° of 5323

- ■2016/08 參加「電子商務巨量資料分析競賽」-季軍
- ■2017/02 參加論譠課程「SparkR 大數據分析實務」

關於資料競賽

·資料分析競賽

- 主辦單位提供去識別化資料、預測標的、競賽平台
- ■參賽者在平台上透過資料分析方法,最佳化預測能力

·資料應用競賽

■使用現有資料進行加值應用



To think, to hack.

競賽過程 = 資料分析流程 + 成果簡報

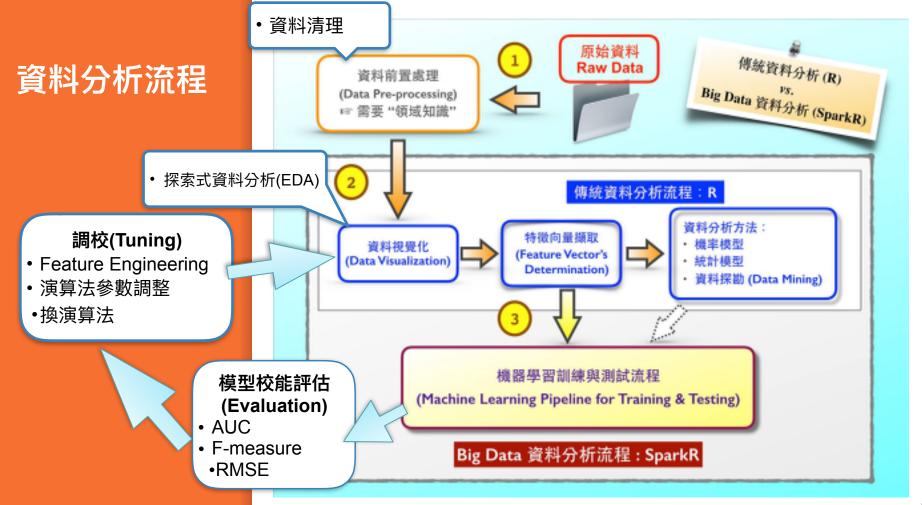
EHC 2016 決賽結果

學生组

F MAN THE STATE OF							
名次	隊名	總分	準確率	程式效能	平行運算	分析作法	創新作法
1	我不知道	44.26	4.60	5.46	15	9.60	9.60
2	CSIE	43.34	6.30	7.24	15	7.60	7.20
3	Watchowl	38.28	3.70	13.58	15	2.80	3.20
4	B!hance	33.50	5.70	15	0	6.80	6.00
5	King	32.80	4.00	5.00	15	4.00	4.80

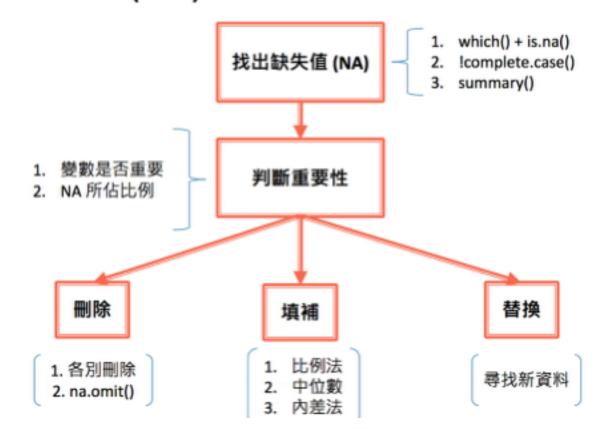
社會組

名次	隊名	總分	準確率	程式效能	平行運算	分析作法	創新作法
1	大GA	48.84	3.70	12.54	15	8.80	8.80
2	數據好好玩	48.66	7.10	14.56	15	6.00	6.00
3	李氏兄弟	46.97	5.40	14.97	15	6.00	5.60
4	DDA	43.00	5.00	5.00	15	9.20	8.80
5	mick	40.40	5.60	15.00	15	2.80	2.00



資料清理

缺失值 (NA) 處理

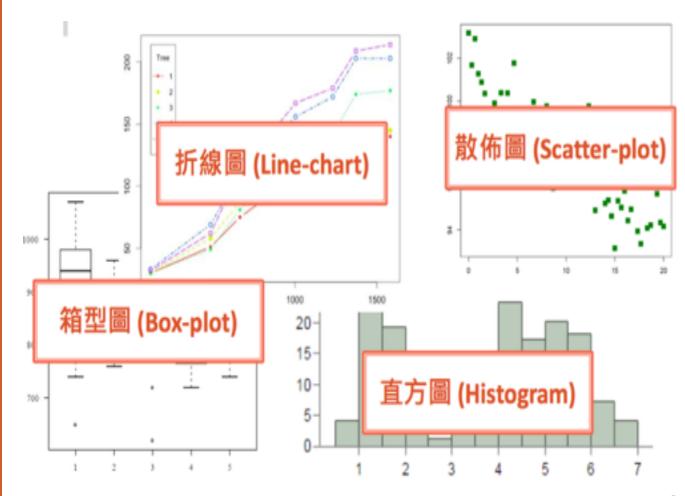


探索式資料分析(Exploratory Data Analysis)

-什麼是 EDA?

- 一種初步分析的方法 (或態度),主要是透過畫圖的方式,達到三個主要的目的
 - 最大化對資料的了解
 - •找出重要的變數
 - 發現 outliers 或異常數值
- 不做過度假設地從原始數據看出隱含意義

EDA 常用的 視覺化方式



特徵向量擷取(Feature Extraction)

■Feature Extraction的目的

- -經過資料清理及EDA後,選取分析所需之Feature
 - ■一般不會把ID、序號等拿來分析
- •依演算法特性處理後作為演算法的input
 - ■EX: 線性演算法前將Feature作normalized
 - •EX: Spark.naiveBayes只接受categorical feature

模型訓練 (Model Training)

■ 擷取後的Feature輸入選定 的演算法產生Model

Spark MLlib						
	Categorical	Continuous				
	Qualitative	Quantitative				
Unsupervised	Clustering	Dimension Reduction				
Extracting structure	K-means	Singular Value Decomposition (SVD) Principal Component Analysis (PCA)				
Supervised	Classification Naive Bayes	Regression linear models				
Making prediction	Decision Trees Ensembles of Trees (Random Forests and Gradient-Boosted Trees)	Support Vector Machines logistic regression linear regression				
Recommender	Collaborative Filtering					
Associating user item	Alternating Least Squares (ALS)					
Optimization		Optimization				
Finding minima		Stochastic Gradient Descent Limited-memory BFGS (L-BFGS)				
Feature Extraction	Feature Extraction Transformation					
Processing text	TF-IDF - Word2Vec Standard Scaler - Normalizer					

模型校能評估(Evaluation)

•透過特定方法評估Model的預測效果

- •Clustering:組內最小平方和(WCSS)
- •Classification: AUC \ F-Measure \ Accuracy
- -Regression : RMSE(Root Mean Square Error)

分類問題常用校能評估指標

		predicted	condition				
	total population prediction positive		prediction negative	$= \frac{\frac{\text{Prevalence}}{\Sigma \text{ condition positive}}}{\frac{\Sigma \text{ total population}}{}}$			
true	condition True Positive (TP)		False Negative (FN) (type II error)	True Positive Rate (TPR), Sensitivity, Recall, Probability of Detection $= \frac{\Sigma \text{ TP}}{\Sigma \text{ condition positive}}$	$\begin{aligned} & \text{False Negative Rate (FNR),} \\ & = \frac{\text{Miss Rate}}{\Sigma \text{ FN}} \\ & = \frac{\Sigma \text{ FN}}{\Sigma \text{ condition positive}} \end{aligned}$		
condition	condition negative	False Positive (FP) (Type I error)	True Negative (TN)	False Positive Rate (FPR), Fall-out, Probability of False Alarm $= \frac{\Sigma \text{ FP}}{\Sigma \text{ condition negative}}$	$\begin{aligned} & \text{True Negative Rate (TNR),} \\ & \text{Specificity (SPC)} \\ & = \frac{\Sigma \text{ TN}}{\Sigma \text{ condition negative}} \end{aligned}$		
	$= \frac{\frac{\text{Accuracy}}{\sum \text{TP} + \sum \text{TN}}}{\sum \text{total population}}$	$\begin{aligned} & \text{Positive Predictive Value (PPV),} \\ & = \frac{\text{Precision}}{\sum \text{TP}} \\ & = \frac{\sum \text{prediction positive}}{\sum \text{prediction positive}} \end{aligned}$	$\frac{\text{False Omission Plate (FOPI)}}{\sum \text{FN}} = \frac{\sum \text{FN}}{\sum \text{prediction negative}}$	Positive Likelihood Ratio (LR+) = TPR FPR	Diagnostic Odds Ratio (DOR) $= \frac{LR+}{LR-}$		
		False Discovery Rate (FDR) $= \frac{\Sigma \text{ FP}}{\Sigma \text{ prediction positive}}$	$\frac{\text{Negative Predictive Value (NPV)}}{\Sigma \ \text{TN}} = \frac{\Sigma \ \text{TN}}{\Sigma \ \text{prediction negative}}$	Negative Likelihood Ratio (LR-) = FNR TNR	- LR-		

- ▶ Recall(實際為1,也被正確判定為1的比例)=> TPR=TP/(TP+FN)
- ▶ Precision(判定為1,實際也為1的比例)=> PPV=TP/(TP+FP)
- Accuracy(正確答對的比例)=> ACC=(TP+TN)/(P+N)

模型調校(Model Tuning)

·演算法參數調校

-EX: 嘗試RandomForest的Tree數量、樹深度及分枝數

■特徵工程(Feature Engineering)

■取得更多特徵值、改變特徵值的呈現(EX:One-hot encoding)來提升演算法效能

Categorical Features的處理

- ▶ 部份演算法(如LogisticRegression)對Categorical欄位處理 能力較差,因此針對類別型態的Feature需作one-of-k(onehot) encoding
- One-of-K encoding:
 - ○長度為N的整數陣列(N=欄位類別的數量)
 - 陣列中類別對應的index設為1,其它為0

	weather	Value	*** #L 10 10 EV	weathersit	Index		Index	Encode
	Clear	1	產生INDEX Map	1	0	Encoding	0	1000
	Mist	2		2	1		1	0100
	Light Snow	3		3	2		2	0010
1	Heavy Rain	4		4	3		3	0001

Let's Kaggle!!!

https://www.kaggle.com/ competitions





(intel)

Intel & MobileODT Cervical Cancer Screening

Which cancer treatment will be most effective? Featured - 3 months to po-

\$100,000 166 teams

Google Cloud & YouTube-8M Video Understanding Challenge Can you produce the best video tag predictions? Featured - 2 months to go

\$100,000 340 teams

Quora Question Pairs Featured - 2 months to go

Can you identify question pairs that have the same intent?

\$25,000 721 teams

Two Sigma Connect: Rental Listing Inquiries

How much interest will a new rental listing on RentHop receive? Recruitment - a month to go

1.540 teams

Jobs

March Machine Learning Mania 2017

Predict the 2017 NCAA Basketball Tournament Playground - 10 days to go

Swag 442 teams

練功區

徵才區

競賽區

Transfer Learning on Stack Exchange Tags

Predict tags from models trained on unrelated topics Playground - 13 hours to go

Titanic: Machine Learning from Disaster

375 teams

6,109 teams

House Prices: Advanced Regression Techniques Predict sales prices and practice feature engineering, RFs, and gradient boosting Getting Started - 3 years to go

Getting Started - 3 years to go - Entered

2.065 teams

入門區



Learn computer vision fundamentals with the famous MNIST data Getting Started - 3 years to go

1.515 teams

Kaggle - 數據分析競賽平台 Kaggle

- -2010/4創立
- -是一個數據建模和數據分析競賽平台
- 企業和研究者可在其上發布數據,統計學者和數據挖掘專家可在其上進行競賽以產生最好的模型

Kaggle 的模組

-Competitions競賽

■獎金競賽、Recruitment(徵才)、Playground(練習)、Getting Started(入門)

Datasets數據集

■提供Open Data下載、資料分析Code及論譠

-Kernel核心

■ 能實作並分享所有數據科學工作的平台,包括與本地工具的結合、團隊間的私有合作空間

-Discussion論壇

任何問題都可在論譠提出,也可在此回覆問題

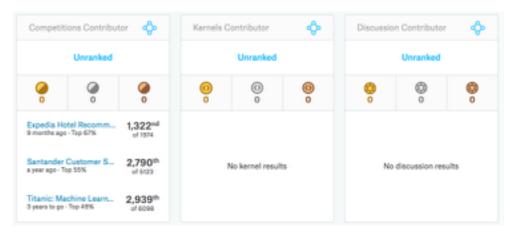
-Jobs求職

*資料分析相

Kaggle的排名

●排名系統

- 等級由低至高分別是Novice、Contributor、Expert、Master和Grandmaster
- Competitions中完成指定類型的比賽、在Kernels中分享代碼、在Forum中回答他人的問題都可以累計積分



Getting Started – Titanic

<u>https://www.kaggle.com/c/titanic</u>

